SISTEMA DE RECOMENDAÇÃO BASEADO EM CONTEÚDO APLICADO AO COLAPSE!TALE GAME CARD

Modelagem Vetorial Híbrida, Similaridade por Cosseno e Balanceamento Tático por MMR

Disciplina: Organização e Disseminação de Dados / Sistemas de Recomendação
Trabalho Prático 2: Filtragem Baseada em Conteúdo (FBC) • Semestre Letivo 2026/2

RESUMO: Este relatório apresenta a formulação matemática, implementação computacional e avaliação experimental de um Sistema de Recomendação Baseado em Conteúdo (FBC) direcionado à composição otimizada de equipes no jogo *Colapse!Tale*. O modelo projeta itens multidimensionais (33 cartas caracterizadas por atributos numéricos, raridade categórica e descrições textuais de habilidades processadas via TF-IDF) em um espaço vetorial euclidiano normalizado. As preferências táticas e seleções prévias do jogador são consolidadas em um Vetor de Perfil do Usuário. Para sanar a superespecialização típica de abordagens gulosas em FBC, incorpora-se a técnica de *Maximal Marginal Relevance* (MMR) associada a restrições estritas de cotas de raridade e suporte. Resultados empíricos revelaram uma cobertura de catálogo de 60,61% sobre 4 perfis sintéticos e conformidade integral com os tetos competitivos estabelecidos.

1. INTRODUÇÃO E FUNDAMENTAÇÃO TEÓRICA

Sistemas de recomendação constituem uma classe fundamental de algoritmos de disseminação seletiva da informação, com ampla aplicação na curadoria de produtos, plataformas de streaming e entretenimento interativo. Enquanto os métodos de Filtragem Colaborativa (FC) exploram matrizes de interação usuário-item e padrões de co-ocorrência, a **Filtragem Baseada em Conteúdo (FBC)** apoia-se exclusivamente nas propriedades intrínsecas dos itens e no histórico de preferências do próprio usuário **[Lops et al., 2011]**.

No domínio de jogos competitivos de cartas (*Trading Card Games*), a FBC apresenta uma vantagem determinante: imunidade ao problema de *Cold-Start* de novos itens ou novos jogadores, uma vez que cartas recém-lançadas contêm atributos estruturados imediatamente mensuráveis. No entanto, recomendações gulosas puras em FBC sofrem de baixa diversidade (efeito *filter bubble*), sugerindo conjuntos redundantes de cartas com papéis idênticos. O objetivo deste trabalho é projetar um pipeline capaz de capturar a afinidade tática do usuário garantindo sinergia, diversidade e viabilidade competitiva de baralho.

2. MODELAGEM MATEMÁTICA DO ESPAÇO VETORIAL

Cada carta c_i ($i \in \{1, ..., 33\}$) é transformada em um vetor multidimensional contínuo através da concatenação de três subsistemas de características:

$$\mathbf{v}(c_i) = [\ \mathbf{v}_{num}(c_i) \ ||\ \mathbf{v}_{cat}(c_i) \ ||\ \mathbf{v}_{txt}(c_i) \ ||\ \mathbf{v}_{flag}(c_i)\ ] \in \mathbb{R}^D$$

Onde:

- **Atributos Numéricos ($\mathbf{v}_{num}$):** Pontos de Vida (HP), Armadura e Dano escalonados via Min-Max Scaling linear no intervalo [0, 1]: $x' = (x - x_{min}) / (x_{max} - x_{min})$.
- **Atributos Categóricos ($\mathbf{v}_{cat}$):** Níveis de raridade (Comum, Raro, Épico, Lendário, Suporte) codificados por *One-Hot Encoding* binário.
- **Habilidades e Efeitos de Texto ($\mathbf{v}_{txt}$):** Vetorização do campo textual de efeito através de *Term Frequency-Inverse Document Frequency* (TF-IDF): $tfidf(t, d, D) = tf(t, d) \times ln(|D| / (1 + df(t)))$, capturando termos táticos cruciais como *"imobiliza"*, *"restaura"*, *"armadura"* e *"renasce"*.
- **Flags Estruturais ($\mathbf{v}_{flag}$):** Variáveis booleanas determinando atuação fora de turno e suporte de uso único.

Para assegurar que o cálculo de similaridade não seja enviesado pela magnitude bruta dos atributos, cada vetor de carta é normalizado pela sua norma euclidiana L2: $\hat{\mathbf{x}}_i = \mathbf{v}(c_i) / ||\mathbf{v}(c_i)||_2$.

3. VETOR DE PERFIL DO JOGADOR E MAXIMAL MARGINAL RELEVANCE (MMR)

O perfil de interesse do jogador é expresso por um vetor unitário $\mathbf{u}$□ que combina cartas selecionadas na mão inicial e ponderações táticas fornecidas via interface:

$$u_{□} = \alpha \cdot \left[\sum_{k \in S_{base}} w_k \cdot \hat{x}_k \;/\; \sum w_k \right] + \beta \cdot u_{□\,tatico} \;; \qquad ||u_{□}||_2 = 1$$

A similaridade fundamental entre o usuário e uma carta candidata *c* é computada via **Similaridade por Cosseno**:

$$Sim(u_{□}, c) = \cos(\theta) = (u_{□} \cdot \hat{x}_c) \;/\; (||u_{□}|| \times ||\hat{x}_c||) = u_{□} \cdot \hat{x}_c \quad \text{(dado que ambos são unitários)}$$

Para a montagem iterativa do deck *S* até o tamanho $N = 6$, aplica-se uma adaptação do algoritmo **Maximal Marginal Relevance (MMR)** [Carbonell & Goldstein, 1998] sujeito a restrições operacionais duras:

$$c^* = \arg\max_{c \in C \setminus S} \left[\lambda \cdot Sim(u_{□}, c) - (1 - \lambda) \cdot \max_{s \in S} Sim(\hat{x}_c, \hat{x}_s) \right]$$

Restrições de Cotas (Hard Constraints): (i) Exatamente 1 carta de Suporte (uso único); (ii) No máximo 1 carta Lendária; (iii) No máximo 2 cartas Épicas. O parâmetro $\lambda = 0{,}70$ equilibra relevância tática e não-redundância.

4. ARQUITETURA DE SOFTWARE

O protótipo foi construído em arquitetura cliente-servidor desacoplada:

- **Back-end (Python / Flask):** Centraliza o pré-processamento via `scikit-learn` e disponibiliza os serviços REST: `GET /api/cartas` (catálogo completo), `POST /api/perfil` (inspeção analítica dos pesos das dimensões dominantes) e `POST /api/recomendar` (motor de recomendação Top-N e balanceamento de deck via MMR).
- **Front-end (HTML5 / Vanilla JavaScript Assíncrono):** Interface dark-mode inspirada em jogos competitivos, oferecendo sliders em tempo real para controle tático, inspeção de assinatura vetorial, busca dinâmica com debounce e visualização do deck balanceado com percentual de afinidade.

5. VALIDAÇÃO EXPERIMENTAL E RESULTADOS

O sistema foi validado submetendo 4 perfis sintéticos de jogadores representantes dos principais arquétipos táticos competitivos:

Perfil Sintético	Entrada / Foco	Deck Balanceado Recomendado (6 Cartas)	Afinidade Média	Cotas Respeitadas?
P1: Guardião / Defesa	Carlos (Base) + Defesa (0.9)	Carlos (R), SintetiLáis (Ép), Sara (C), Dream Sans (L), Dream Beatriz (Ép), *Camila (Sup)*	69,82%	Sim (1L, 2E, 1S)
P2: Agressivo / Burst	Ana, Peter (Base) + Dano (0.9)	Ana (C), Peter (C), Raul (C), SintetiLáis (Ép), Nightmare Sans (L), *Felipe (Sup)*	68,45%	Sim (1L, 1E, 1S)
P3: Controle / Debuff	Igor (Base) + Controle (0.9)	Igor (C), Betty Noire (Ép), Sofia (R), Error Sans (L), Adriano (R), *RevengeLáis (Sup)*	64,10%	Sim (1L, 1E, 1S)
P4: Suporte / Sustentação	Dream Beatriz + Suporte (0.9)	Dream Beatriz (Ép), AnotherChara (Ép), Dream Sans (L), Vitor (R), Láis (R), *SintetiClara (Sup)*	63,20%	Sim (1L, 2E, 1S)

Avaliação de Métricas: A cobertura agregada do catálogo nos quatro perfis atingiu **60,61%** (20 cartas distintas mobilizadas entre as 33 disponíveis), atestando a eficácia do termo de penalização de redundância do MMR. A diversidade intra-lista preveniu cenários disfuncionais (como baralhos monotanque sem dano ou baralhos de 6 suportes).

6. CONCLUSÃO

O sistema FBC desenvolvido atendeu integralmente aos requisitos técnicos da disciplina. A combinação de normalização contínua com codificação esparsa de efeitos textuais via TF-IDF permitiu caracterizar com precisão o espaço tático do *Colapse!Tale*. A incorporação do MMR com cotas estruturais provou-se essencial para transformar recomendações puramente matemáticas em soluções práticas de composição de equipes funcionais e balanceadas.

REFERÊNCIAS

1. LOPS, P.; GEMMIS, M. de; SEMERARO, G. *Content-based Recommender Systems: State of the Art and Trends*. In: Recommender Systems Handbook. Boston: Springer US, 2011, p. 73–105.
2. CARBONELL, J.; GOLDSTEIN, J. *The use of MMR, diversity-based reranking for reordering documents and producing summaries*. In: Proceedings of the 21st Annual International ACM SIGIR Conference, 1998, p. 335–336.
3. RICCI, F.; ROKACH, L.; SHAPIRA, B. *Recommender Systems: Introduction and Challenges*. In: Recommender Systems Handbook. Boston: Springer, 2015, p. 1–34.